

Article 1 : ThaiNutriChat (Le Chatbot Nutritionnel)

Sujet : Un chatbot pour conseiller les patients thaïlandais sur les maladies chroniques (diabète, hypertension).

✓ Points Forts :

Précision Spécialisée : Il surpasse GPT-3.5 sur des questions médicales thaïlandaises spécifiques avec 92,8% de réponses correctes.

Adaptation Locale : Utilisation de documents provenant d'organisations de santé locales, ce qui garantit que les conseils respectent la culture et les ressources du pays.

Hybridation : L'étude prouve que combiner le RAG avec le Fine-tuning (LoRA) est bien plus efficace que d'utiliser une seule méthode.

✗ Points Faibles :

Problème d'OCR : La langue thaï est difficile à numériser ; les erreurs de lecture des textes originaux ont nécessité beaucoup de nettoyage manuel.

Portée Limitée : Le chatbot fonctionne très bien pour les maladies chroniques, mais perd en efficacité dès qu'on sort de ce domaine précis.

② Article 2 : LLM QA Chatbot Builder (La Plateforme de Construction)

Sujet : Un outil "tout-en-un" pour créer des chatbots sans avoir besoin de grandes compétences en programmation.

✓ Points Forts :

Automatisation Complète : Il gère tout le cycle : crawling du web, nettoyage des données, entraînement (Fine-tuning) et interface de chat.

Accessibilité : Permet à des utilisateurs non-techniques de créer leur propre IA personnalisée.

Optimisation Matérielle : Utilise la quantification (4-bit/8-bit) pour permettre au système de tourner sur des PC classiques.

✗ Points Faibles :

Biais d'Évaluation : L'étude souligne que l'utilisation de GPT-4 pour noter le chatbot peut être biaisée ou manquer de contexte humain.

Besoin de Données de Qualité : Si l'utilisateur fournit des données de mauvaise qualité via le crawler, le chatbot produira des résultats médiocres (Overfitting).

③ Article 3 : Évaluation du Chatbot MRONJ (L'Expert Médical)

Sujet : Utilisation du RAG pour répondre à des questions sur une pathologie rare de la mâchoire (ostéonécrose).

✓ Points Forts

Fiabilité Clinique : Le système est "Context-Aware" (conscient du contexte), ce qui signifie qu'il cite ses sources médicales, réduisant ainsi les risques de fausses informations (hallucinations).

Utilité Pratique : Il aide les dentistes généralistes à prendre des décisions rapides sur des cas complexes sans attendre un spécialiste.

✗ Points Faibles :

Dépendance au RAG : Si les documents de référence ne contiennent pas la réponse exacte, le modèle peut parfois inclure des données non pertinentes juste pour essayer de répondre.

Évaluation Restreinte : Testé principalement par des experts, il reste à voir comment des étudiants ou des patients réagiraient face à ses conseils

2. Architecture Technique du Chatbot (Comment ça marche ?)

L'architecture de votre chatbot repose sur une approche hybride combinant la puissance de calcul des LLM et la précision des données externes.

A. Le Pipeline de Données (Ingestion)

Le système ne se contente pas de ce qu'il a appris durant son entraînement initial. Il s'enrichit via :

Web Crawling & Scraping : Récupération automatisée d'articles

Traitement OCR : Conversion des documents PDF et images en texte

Traitement de l'Arabe (OCR & Segmentation) : Comme dans *ThaiNutriChat*, on utilise des outils pour lire les caractères arabes et segmenter les mots (car l'arabe est une langue riche en morphologie).

Vectorisation : Les articles sont découpés en "morceaux de savoir" et rangés dans une base de données

B. Le Cerveau : Hybridation RAG + Fine-Tuning

Pour garantir une performance maximale (comme prouvé par *ThaiNutriChat*), l'architecture utilise deux leviers

Modèle de base : Un modèle capable de gérer l'arabe et anglais

RAG (Retrieval-Augmented Generation) :

- Le chatbot cherche les 3 meilleurs articles dans sa mémoire.
- • Il combine ces articles avec la question.
- • Il génère une réponse en citant les auteurs et les dates de publication
-

Fine-Tuning (LoRA) : Le modèle est "ajusté" avec des techniques légères (4-bit/8-bit) pour mieux comprendre le langage spécifique sans nécessiter de supercalculateurs.

Recherche de Labos : "Quels chercheurs travaillent sur le NLP arabe en Algérie ?"

Re-ranking Intelligent : Trier les résultats de recherche pour ne donner que les articles les plus cités (les plus fiables).

Évaluation par les Pairs : Permettre aux professeurs de noter les réponses du chatbot pour améliorer sa base de connaissances

Pipeline Automatisé : Dès qu'un nouveau papier de recherche sort sur le NLP arabe, le chatbot le lit et l'ajoute à sa mémoire automatiquement