

Rapport Technique

Chatbot Juridique Multilingue

Architecture Révisée et Améliorations Proposées

Projet : Chatbot Juridique Multilingue avec RAG
Équipe : Bettayeb Mohamed Aimen, Amina, Yanis, Loubna
Encadrante : Mme Berkani
Date : Mars 2026
Version : 2.0 — Architecture Révisée

Table des matières

1	Résumé Exécutif	2
2	Contexte et Problématique	2
2.1	Motivation du Projet	2
2.2	Problème Central	2
2.3	Critique de l'Architecture Précédente	2
3	Architecture Globale du Pipeline	2
4	Module 1 — Détection de Langue	3
4.1	Technique 1 — Analyse de Script Unicode	3
4.2	Technique 2 — Détection Statistique	3
5	Module 2 — Classification d'Intention (Révisé)	3
5.1	Problèmes avec l'Ancienne Approche	3
5.2	Nouvelle Approche — LLM Zero-Shot	3
5.3	Résolution de Contexte Conversationnel	3
6	Module 3 — Routage des Requêtes	4
7	Module 4 — Représentation Vectorielle (Révisé)	4
7.1	Changement de Modèle	4
7.2	Similarité Cosinus	4
8	Module 5 — Retrieval Hybride Réel (Révisé)	4
8.1	Problème avec l'Ancienne Approche	4
8.2	Nouvelle Approche	4
8.3	Fusion RRF	4
9	Module 6 — Déduplication	5
10	Module 7 — Reranking	5
11	Module 8 — Construction du Contexte (Révisé)	5
11.1	Balanced Selection	5
11.2	Chunking Structure-Aware	5
12	Module 9 — Génération LLM	5

13 Module 10 — Vérification de Fidélité (Nouveau)	5
14 Tableau Récapitulatif des Changements	6
15 Méthodologie d'Évaluation	6
16 Références Bibliographiques	6

1 Résumé Exécutif

Ce rapport présente l'architecture complète et révisée du chatbot juridique multilingue développé dans le cadre du projet de fin d'études. Suite aux remarques formulées lors de la dernière séance concernant la nature arbitraire de certaines formules mathématiques utilisées dans le module de classification d'intention, nous avons procédé à une analyse critique de l'ensemble de l'architecture existante. Ce document décrit les modifications apportées, les justifications théoriques de chaque décision de conception, et les améliorations attendues.

2 Contexte et Problématique

2.1 Motivation du Projet

L'accès aux réglementations légales et administratives au sein des institutions académiques représente un défi majeur pour les étudiants et les chercheurs. Les textes juridiques sont rédigés dans un langage complexe, distribués sur de nombreux documents hétérogènes, et disponibles en plusieurs langues (arabe, français, anglais).

Exemple concret : Un doctorant dont le directeur de thèse décède en cours de parcours doit suivre des procédures administratives précises définies par les textes réglementaires universitaires. Sans outil adapté, il doit manuellement parcourir de nombreux documents pour identifier les démarches requises.

Notre système propose une solution conversationnelle permettant aux utilisateurs de poser des questions en langage naturel dans leur langue maternelle et d'obtenir des réponses fondées et vérifiées.

2.2 Problème Central

Les modèles de langage génératifs peuvent produire des informations juridiques incorrectes avec une haute confiance apparente. Dans un contexte juridique, une réponse erronée peut avoir des conséquences réelles. L'architecture Retrieval-Augmented Generation (RAG) est adoptée : les réponses sont ancrées dans des documents externes vérifiés.

2.3 Critique de l'Architecture Précédente

Suite à la remarque de Mme Berkani lors de la dernière séance, nous avons identifié que la principale faiblesse résidait dans le module de classification d'intention. Ce module utilisait une formule heuristique :

$$\text{score}_i = \text{base}_i + 0.03 \times \min(m_i - 1, 3) \quad (1)$$

Les constantes choisies (0.03, 0.85, 0.15) n'avaient pas été validées empiriquement. De plus, les patterns regex étaient principalement rédigés en anglais et français, créant une lacune pour le traitement des requêtes en arabe pur.

3 Architecture Globale du Pipeline

Le pipeline révisé comprend : Détection de langue (Unicode + langdetect) → Résolution de contexte conversationnel → Classification d'intention (LLM Zero-Shot) → Routage → Représen-

sentation vectorielle (BGE-M3) → Retrieval hybride (Dense + BM25 + RRF) → Déduplication (Jaccard) → Reranking → Construction du contexte → Génération LLM → Vérification de fidélité → Réponse finale.

4 Module 1 — Détection de Langue

4.1 Technique 1 — Analyse de Script Unicode

Les caractères arabes sont détectés par une expression régulière couvrant les plages Unicode arabes. Le ratio arabe :

$$R_{\text{arabic}} = \frac{N_{\text{ar}}}{N_{\text{alpha}}} \geq 0.30 \implies \text{lang} = \text{ar} \quad (2)$$

Le seuil 0.30 offre le compromis optimal entre robustesse au code-mixing et précision, conformément aux pratiques documentées (langdetect, pylld2).

4.2 Technique 2 — Détection Statistique

Si le texte n'est pas arabe, la bibliothèque `langdetect` est utilisée. Formule (Maximum Likelihood) :

$$L^* = \arg \max_L P(L | T) = \arg \max_L P(T | L) \cdot P(L) \quad (3)$$

5 Module 2 — Classification d'Intention (Révisé)

5.1 Problèmes avec l'Ancienne Approche

Problème 1 — Lacune linguistique : Les patterns regex étaient en anglais et français. Une requête en arabe ne correspondait à aucun pattern et était classifiée par défaut comme `general_knowledge`.

Problème 2 — Constantes sans validation : Le coefficient 0.03, les scores de base, le seuil 0.15 ont été choisis par intuition sans validation sur données réelles.

Problème 3 — Maintenance : Chaque nouvelle formulation nécessite l'ajout manuel d'un pattern regex.

5.2 Nouvelle Approche — LLM Zero-Shot

La requête est envoyée au LLM avec un prompt structuré décrivant les intents : `legal_query`, `document_query`, `general_knowledge`. Le LLM retourne l'intent approprié en s'appuyant sur sa compréhension sémantique, indépendamment de la langue.

5.3 Résolution de Contexte Conversationnel

Avant la classification, une étape de réécriture de requête pour les conversations multi-tours : le système réécrit la question de suivi sous forme d'une question complète et autonome incluant le contexte de l'historique.

6 Module 3 — Routage des Requêtes

Intent	Source
legal_query	Qdrant — legal_documents
document_query	Qdrant — document_chunks
general_knowledge	LLM directement

7 Module 4 — Représentation Vectorielle (Révisé)

7.1 Changement de Modèle

Ancien : paraphrase-multilingual-mpnet-base-v2 (768 dimensions, support arabe limité).

Nouveau recommandé : BAAI/bge-m3 ou intfloat/multilingual-e5-large. BGE-M3 (2024) : entraîné sur un corpus multilingue plus large, optimisé pour le retrieval, génère vecteurs denses et sparses, performances supérieures sur MIRACL incluant l'arabe.

7.2 Similarité Cosinus

$$\cos(q, d) = \frac{q \cdot d}{\|q\| \|d\|} = \frac{\sum q_i d_i}{\sqrt{\sum q_i^2} \cdot \sqrt{\sum d_i^2}} \quad (4)$$

Invariance à la norme ; borné dans $[0, 1]$; standard IR (Salton & McGill, 1983).

8 Module 5 — Retrieval Hybride Réel (Révisé)

8.1 Problème avec l'Ancienne Approche

L'architecture précédente était une recherche sémantique avec pondération manuelle : $s_{\text{final}}(q, d, s) = \cos(q, d) \times w_s$ avec $w_s = 1.05$. Aucune composante lexicale ; poids arbitraire.

8.2 Nouvelle Approche

Composante 1 — Dense : Qdrant avec embeddings BGE-M3.

Composante 2 — Sparse : BM25 sur les tokens.

$$\text{BM25}(q, d) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \cdot (1 - b + b \cdot |d|/\text{avgdl})} \quad (5)$$

Avec $k_1 = 1.5$, $b = 0.75$.

8.3 Fusion RRF

$$\text{RRF_score}(d) = \frac{1}{k + \text{rank}_{\text{dense}}(d)} + \frac{1}{k + \text{rank}_{\text{sparse}}(d)} \quad (6)$$

Avec $k = 60$ (Cormack et al., 2009). Aucun paramètre arbitraire ; insensible aux échelles ; robuste.

9 Module 6 — Déduplication

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \quad J(A, B) \geq 0.85 \implies \text{duplicat} \quad (7)$$

Seuil 0.85 : pratique établie (Manku et al., 2007).

10 Module 7 — Reranking

$$\text{score}_{\text{rerank}}(q, d) = \frac{q \cdot d}{\|q\| \|d\| + \varepsilon}, \quad \varepsilon = 10^{-9} \quad (8)$$

Recalcule la similarité cosinus sur les candidats restants. Top-5 chunks retenus.

11 Module 8 — Construction du Contexte (Révisé)

11.1 Balanced Selection

$\forall f \in \mathcal{F}, |\mathcal{R}_f| \geq 2$ (MIN_PER_DOC = 2).

11.2 Chunking Structure-Aware

Priorité 1 : frontières d'articles (Article X, Art. X, X). Priorité 2 : paragraphes. Priorité 3 : phrases. Priorité 4 : tokens (512, overlap 64) en fallback. CHUNK_SIZE = 512, CHUNK_OVERLAP = 64 (Lewis et al., 2020).

12 Module 9 — Génération LLM

Le prompt intègre : contexte récupéré, requête (réécrite si multi-tours), historique, instructions de citation. Estimation des tokens : $\hat{T}(x) = \max(1, \lfloor |x|/4 \rfloor)$.

13 Module 10 — Vérification de Fidélité (Nouveau)

Après génération, le LLM vérifie si chaque affirmation est supportée par le contexte. Répond **faithful** ou **not_faithful**. Si **not_faithful** : réponse de fallback sécurisée recommandant la consultation des textes ou du service administratif.

14 Tableau Récapitulatif des Changements

Composant	Précédent	Révisé	Raison
Classification	Regex + heuristique	LLM Zero-Shot	Agnostique langue
Retrieval	Sémantique pondérée	Dense + BM25 + RRF	Références exactes
Embedding	mpnet-base-v2	BGE-M3	Support arabe
Chunking	Fixe 512	Hiérarchique	Frontières articles
Post-génération	Aucune	Vérification fidélité	Anti-hallucination
Conversations	Historique brut	Réécriture requête	Références pronominales
Cosinus, Jaccard, Top-K=5, MIN_PER_DOC=2, BERTScore, P@k/R@k/MRR	Conservés		

15 Méthodologie d'Évaluation

Retrieval : $P@k$, $R@k$, $MRR = (1/Q) \sum_{i=1}^Q 1/\text{rank}_i$.

Génération : BERTScore (similarité sémantique vs BLEU/ROUGE lexical).

Humaine : Exactitude, complétude, clarté, citation des sources.

Vérification fidélité : Taux de détection hallucinations, faux positifs, fallback.

16 Références Bibliographiques

1. Salton, G. & McGill, M.J. (1983). *Introduction to Modern Information Retrieval*. McGraw-Hill.
2. Lewis, P. et al. (2020). "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." NeurIPS.
3. Manku, G.S., Jain, A., & Das Sarma, A. (2007). "Detecting Near-Duplicates for Web Crawling." WWW.
4. Reimers, N. & Gurevych, I. (2019). "Sentence-BERT." EMNLP.
5. Zhang, T. et al. (2019). "BERTScore." ICLR 2020.
6. Bruch, S., Gai, A., & Ingber, A. (2022). "Fusion Functions for Hybrid Retrieval." arXiv :2210.11934.
7. Nogueira, R. & Cho, K. (2019). "Passage Re-ranking with BERT." arXiv :1901.04085.
8. Cormack, G.V., Clarke, C.L.A., & Buettcher, S. (2009). "Reciprocal Rank Fusion." SIGIR.
9. Chen, J. et al. (2024). "BGE M3-Embedding." arXiv :2402.03216.
10. Robertson, S. & Zaragoza, H. (2009). "BM25 and Beyond." Foundations and Trends in IR.

Annexe — Constantes

Constante	Valeur	Source
Seuil arabe	0.30	Code-mixing
RRF k	60	Cormack et al. (2009)
Seuil Jaccard	0.85	Manku et al. (2007)
ε rerank	10^{-9}	Stabilité numérique
Chunk size	512	BERT/MPNet
Chunk overlap	64	Lewis et al. (2020)
Top-K	5	Budget LLM
MIN_PER_DOC	2	Couverture
BM25 k_1	1.5	Standard
BM25 b	0.75	Standard

Rapport rédigé par l'équipe PFE — Mars 2026
Bettayeb Mohamed Aimen | Amina | Yanis | Loubna